



Universidad Argentina de la Empresa
Facultad de Ingeniería y Ciencias Exactas

Trabajo Práctico Obligatorio

Ciencia de Datos (3.4.217)

Grupo 7

Dominio del Negocio e Hipótesis

Comisión	6423 — Viernes 07:45–11:45
Docente	Santiago Gabriel Martin
Cuatrimestre	1.º cuatrimestre 2026
Dominio elegido	No-show de turnos médicos
Integrantes	Arbe, Candelaria — 1175530 Fernandez, Candela — 1180678 Brander, Tomás — 1096951 Nombre Apellido — LU] · [Nombre Apellido — LU]
Fecha de entrega	[completar]

Índice

1. Selección del Dominio del Negocio	3
1.1. Descripción del dominio	3
1.2. Problemática	3
1.3. Propuesta de valor	3
1.4. Fuentes de datos	3
2. Desarrollo de la Hipótesis	4
2.1. Hipótesis: qué proponemos resolver	4
2.2. Audiencia	4
2.3. Cómo se resuelve la hipótesis para la entrega de valor	5
3. Metodología de trabajo y organización del equipo	5
3.1. Enfoque metodológico	5
3.2. Roles del equipo	5

1. Selección del Dominio del Negocio

1.1. Descripción del dominio

Un centro de salud ambulatorio (clínica u hospital) atiende a sus pacientes mediante turnos programados. El circuito de atención es el siguiente: el paciente solicita un turno —de forma presencial, telefónica o web—, se le asigna una fecha y un horario con un profesional y, el día indicado, asiste a la consulta o no lo hace.

La agenda del profesional constituye el recurso central del negocio: cada franja horaria tiene un costo fijo —el tiempo del médico— y una capacidad limitada. La gestión eficiente de esa agenda determina cuántos pacientes se atienden y con qué nivel de espera.

1.2. Problemática

El **ausentismo a turnos médicos** (en inglés, *no-show*) ronda el **20–30 %** de los turnos otorgados. Cuando un paciente no asiste y no avisa con antelación, se producen dos efectos negativos simultáneos:

- La franja horaria queda ociosa: una hora del profesional que la institución igualmente debe afrontar.
- Otro paciente que sí habría asistido no pudo ocupar ese lugar, lo que incrementa la lista de espera.

Se trata, por lo tanto, de un **doble costo**: un recurso médico desperdiciado y un peor acceso a la atención para el resto de los pacientes. En la actualidad, la institución no dispone de información anticipada sobre quién faltará, de modo que no puede tomar ninguna acción preventiva.

1.3. Propuesta de valor

La propuesta consiste en predecir, en el momento mismo de agendar el turno, la probabilidad de que cada paciente falte, con el fin de accionar sobre aquellos de mayor riesgo mediante:

- **Recordatorios dirigidos** (SMS o llamado telefónico) a los pacientes con mayor probabilidad de ausentarse.
- **Sobretornos controlados** en las franjas horarias de alto riesgo de ausentismo.

Valor para el negocio: reducción del ausentismo, mejor aprovechamiento de la agenda y disminución de la lista de espera, sin necesidad de incorporar recursos adicionales. Cada turno no perdido recupera una hora efectiva de atención.

1.4. Fuentes de datos

Fuente principal — *Medical Appointment No Shows* (Kaggle)

Atributo	Detalle
----------	---------

Origen	Kaggle — registros reales de turnos de salud pública de Brasil.
Volumen	Más de 110.000 turnos (filas).
Variables (14)	Edad, género, barrio, fechas de agendamiento y de turno, comorbilidades (diabetes, hipertensión, alcoholismo, discapacidad), recepción de SMS, beca social y la variable objetivo: asistió / no asistió.
Justificación	Conjunto de datos limpio, masivo y documentado, con la variable a predecir ya etiquetada. Combina variables categóricas y numéricas, lo que habilita el análisis exploratorio y la ingeniería de características.

Fuente secundaria — Clima por fecha (expectativa superadora)

Atributo	Detalle
Origen	Conjunto de datos o API meteorológica histórica (clima diario por ciudad y fecha).
Integración	Se cruza por la fecha del turno —dato ya presente en la fuente principal—, por lo que la integración es directa.
Justificación	Permite analizar si la lluvia o la temperatura inciden en el ausentismo, y satisface el requisito superador de utilizar varias fuentes de datos distintas.

A confirmar con el docente: ¿el cruce del conjunto de datos principal con el clima por fecha se considera «varias fuentes de datos distintas» a los efectos de la expectativa superadora?

2. Desarrollo de la Hipótesis

Definidos el dominio y las fuentes de datos, se plantea a continuación la pregunta concreta que el proyecto busca responder y el modo en que esa respuesta se traduce en valor para la organización.

2.1. Hipótesis: qué proponemos resolver

Es posible predecir, en el momento en que se agenda un turno, qué pacientes faltarán a la consulta a partir de sus características y del contexto del turno; y utilizar esa predicción para reducir el costo del ausentismo mediante recordatorios dirigidos y la asignación de sobretornos.

La hipótesis es verificable: el modelo predictivo entregará, para cada turno, una probabilidad de ausencia que podrá contrastarse contra lo efectivamente ocurrido, y cuyo acierto se medirá con métricas objetivas (véase sección 2.3).

2.2. Audiencia

Conforme a la consigna, la audiencia del trabajo es la Gerencia Comercial y Técnica. El mensaje se adapta a cada una:

- **Gerencia Comercial:** se enfatiza el impacto en el aprovechamiento de la agenda, los ingresos recuperados por hora-profesional, la reducción de la lista de espera y la mejora en el acceso de los pacientes.
- **Gerencia Técnica:** se detalla el modelo de minería empleado, el pipeline de datos que lo alimenta y las métricas que garantizan la confiabilidad de la predicción.

2.3. Cómo se resuelve la hipótesis para la entrega de valor

La resolución se apoya en una técnica de aprendizaje supervisado de las estudiadas en la asignatura:

- **Técnica:** clasificación binaria (asiste / no asiste) mediante árboles de decisión y Random Forest. La variable objetivo es categórica de dos clases, lo que encuadra el problema como clasificación.
- **Evaluación:** dado que las clases están desbalanceadas (aproximadamente 80 % de asistencia frente a 20 % de ausencia), el desempeño se mide con precision, recall, F1 y AUC, y no únicamente con accuracy —una métrica que, ante este desbalanceo, resultaría engañosa.
- **Entrega de valor:** el modelo devuelve una probabilidad de ausencia por turno; sobre ella, la aplicación funcional recomienda la acción correspondiente (recordatorio o sobreturno). Cada turno no perdido recupera una hora efectiva de atención, materializando el valor propuesto para el negocio.

Coherencia hipótesis–conclusión: la métrica del modelo responde de forma directa a la hipótesis planteada, criterio que la consigna evalúa explícitamente.

3. Metodología de trabajo y organización del equipo

3.1. Enfoque metodológico

El proyecto combina una metodología de ciencia de datos con una metodología ágil de gestión:

- **Proceso de minería de datos — CRISP-DM:** el trabajo recorre sus fases (comprensión del negocio, comprensión de los datos, preparación, modelado, evaluación y despliegue), que se corresponden con las secciones de este proyecto.
- **Gestión del proyecto — metodología ágil:** se adopta un enfoque iterativo basado en Kanban (tablero To Do / Doing / Done en GitHub Projects), con iteraciones cortas alineadas a las entregas parciales de la cátedra para revisar avances y reencauzar el trabajo.
- **Versionado — GitHub:** todo el código del proyecto de datos (notebook de EDA y modelado, y la aplicación funcional) se versiona en un repositorio de GitHub, con commits descriptivos y trabajo por ramas.

Esta combinación responde a las expectativas superadoras de la consigna (administración del proyecto con metodologías ágiles y versionado del código).

3.2. Roles del equipo

Cada integrante asume un rol específico y expone su área de influencia durante la presentación, conforme lo exige la consigna. Los roles propuestos son:

Rol	Responsabilidad	Integrante
Líder de proyecto	Coordina el equipo y la metodología ágil; expone el dominio, la problemática y la propuesta de valor.	[Nombre]
Ingeniero de datos	Selección e ingesta de fuentes (Kaggle y fuente secundaria), limpieza y construcción del pipeline de datos.	[Nombre]
Analista de datos (EDA)	Análisis exploratorio, control de calidad de datos y visualizaciones descriptivas.	Cande Fernandez
Especialista en modelado	Ingeniería de características, entrenamiento del modelo (árbol de decisión / Random Forest) y evaluación con métricas.	[Nombre]
Desarrollador de la aplicación	Construcción de la aplicación funcional interactiva y conexión con el modelo; conclusión y storytelling.	[Nombre]

Nota: ajustar la cantidad de roles a la cantidad de integrantes del grupo; un integrante puede asumir más de un rol si fuera necesario.